

Relatório: Previsão de Preços de Casas

Beatriz Vaz Pedroso Santos Cobral - 2082 - GEC

1. Análise e Entendimento dos Dados

Principais Variáveis

Após o merge e engenharia de features, as variáveis mais relevantes são:

Variável	Tipo	Descrição
price	float	Variável-alvo: preço de venda em USD. Mediana: \$450.000, Média: \$540.088, Máx: \$7.700.000.
sqft_living	int	Área interna habitável em pés quadrados. Maior correlação com preço ($r=0.70$).
grade	int	Nota de qualidade construtiva (1–13) definida pelo Condado de King. $r=0.67$.
sqft_above	int	Área acima do solo, excluindo porão.
bathrooms	float	Número de banheiros. Frações indicam banheiro sem chuveiro.
waterfront	int	Flag binária: 1 se a casa tem frente para a água.
view	int	Qualidade da vista (0–4).
lat / long	float	Coordenadas geográficas — proxy de localização e valorização regional.
medn_incm_per_prsn_amt	float	Renda mediana por pessoa no CEP. $r=0.55$ com preço.
per_prfsnl / per_bchlr	float	% de pós-graduados e graduados por CEP. Capturam demanda de alto poder aquisitivo.
per_hsd / per_9_to_12	float	% sem ensino superior. Correlação negativa com preço ($r\approx-0.49, -0.41$).
renovated	bool	Feature derivada: True se a casa foi reformada alguma vez.
basement	bool	Feature derivada: True se a casa possui porão.
dif_sqft_living	int	Feature derivada: diferença entre a área da casa e a média dos 15 vizinhos. Captura posicionamento relativo no bairro.
dif_sqft_lot	int	Feature derivada: diferença entre o lote da casa e a média dos 15 vizinhos.

Combinação dos Dados Físicos e Demográficos

O merge foi realizado com `pd.DataFrame.merge(how='left')` usando zipcode como chave de junção. A abordagem left join preserva todos os 21.613 imóveis do dataset principal. Os 70 CEPs demográficos cobrem todos os zipcodes presentes em `kc_house_data.csv`, portanto não houve perda de registros após o merge.

A coluna zipcode foi descartada após o merge pois sua informação já está representada pelas variáveis demográficas e pelas coordenadas geográficas (lat/long), evitando que um identificador categórico de alta cardinalidade fosse tratado como variável numérica pelo modelo.

Análise de Outliers

A detecção de outliers foi restrita às variáveis contínuas com semântica mensurável, excluindo deliberadamente variáveis binárias (waterfront, renovated, basement), categóricas ordinais (grade, condition, view, floors) e variáveis com valores semânticos especiais (yr_renovated, onde 0 significa 'nunca reformada', não um valor aberrante).

Padrões identificados:

- casas maiores tendem a possuir preços maiores;
- imóveis reformados possuem valorização significativa;
- regiões com melhores indicadores demográficos apresentam preços mais altos;
- imóveis com vista para água possuem preços muito acima da média.


Dois métodos foram aplicados e comparados:

- Z-score ($|z| > 3$): identifica 1.363 registros com pelo menos uma variável a mais de 3 desvios padrão da média. Método mais conservador.
- IQR ($1.5 \times IQR$): identifica 7.335 registros. Mais sensível a distribuições assimétricas como `sqft_lot`, que naturalmente possui alta variância.


Decisão sobre remoção de outliers:

Após análise manual dos registros, optou-se por remover apenas o registro com `bedrooms=33` (valor improvável para uma residência). Os demais outliers foram mantidos pois representam imóveis legítimos no segmento de luxo: casas com área elevada, lotes grandes ou preços acima de \$1M existem genuinamente.

O registro com `bedrooms=33` foi substituído por NaN e imputado via `KNNImputer (k=5)`, utilizando os 5 vizinhos mais próximos no espaço de features para estimar o valor correto, em vez de simplesmente descartar a linha.



Correlações e Padrões Relevantes



Destaques analíticos:

- sqft_living (r=0.70) e grade (r=0.67) são as features físicas mais correlacionadas com preço, confirmando que tamanho e qualidade construtiva são os principais determinantes de valor.
- As variáveis demográficas medn_incm_per_prsn_amt (r=0.55), per_prfsnl (r=0.50) e per_bchlr (r=0.47) têm correlação superior às coordenadas geográficas, evidenciando que o perfil socioeconômico do CEP carrega informação preditiva relevante além dos atributos físicos.
- per_hsd (r=-0.49) e per_9_to_12 (r=-0.41) apresentam correlação negativa forte: CEPs com maior percentual de população sem ensino superior concentram imóveis de menor valor.
- dif_sqft_living (r=0.41) captura o posicionamento relativo da casa no bairro — uma casa maior que seus vizinhos tende a ser mais valorizada.
- waterfront (r=0.27), apesar de binária, tem impacto significativo: casas com frente para a água alcançam prêmios de preço expressivos.

2. Desenvolvimento do Modelo de Machine Learning

Variáveis Importantes

As 26 features selecionadas foram organizadas em três grupos funcionais:

Categoria	Features
Físicas da Casa	sqft_living, grade, sqft_above, sqft_basement, bathrooms, bedrooms, floors, condition, waterfront, view, basement, sqft_lot, dif_sqft_living, dif_sqft_lot
Temporais / Derivadas	yr_built, renovated
Geográficas / Demográficas	lat, long, medn_incm_per_prsn_amt, medn_hshld_incm_amt, per_prfsnl, per_bchlr, per_urbn, per_assoc, per_9_to_12, per_hsd

Variáveis excluídas e justificativas:

- `hous_val_amt`: data leakage — valor mediano dos imóveis do CEP é derivado dos próprios preços de venda, vazando a variável-alvo para as features.
- `id`, `date`, `zipcode`: identificadores sem valor preditivo ou redundantes com outras variáveis.
- `sqft_living15`, `sqft_lot15`: substituídas pelas features derivadas `dif_sqft_living` e `dif_sqft_lot`, que capturam a mesma informação de forma mais interpretável.
- `yr_renovated`: substituída pela flag binária `renovated`, eliminando o problema do valor semântico 0 (nunca reformada).
- Contagens absolutas demográficas (`ppltn_qty`, `edctn_*_qty` etc.): correlacionadas com o tamanho populacional do CEP, não com o valor do imóvel. Substituídas pelos percentuais correspondentes.

Escolha e Implementação do Modelo

Modelo escolhido: Multi-Layer Perceptron Regressor (Keras/TensorFlow)

Justificativa da escolha:

- Modelos lineares (Regressão Linear, Ridge) atingem tipicamente $R^2 \approx 0.70$ neste dataset — insuficiente para capturar interações não-lineares entre área, localização e preço.
- O dataset possui ~21.600 amostras e 26 features, volume adequado para redes neurais rasas sem overfitting severo.
- Relações não-lineares são bem capturadas por ativações ReLU em múltiplas camadas — por exemplo, o efeito de `waterfront` multiplica o preço de forma não-proporcional ao tamanho.

Arquitetura implementada:

Parâmetro	Valor / Justificativa
<code>hidden_layer_sizes</code>	(64, 32, 16) — funil decrescente, comprime representação gradualmente
<code>activation</code>	<code>relu</code> — evita vanishing gradient, padrão para dados tabulares

Parâmetro	Valor / Justificativa
optimizer	adam — adaptativo, convergência rápida sem tuning manual de lr
loss	mae — erro absoluto médio, mais interpretável para preços em USD
batch_size	32
epochs	100
saída	Dense(1) sem ativação — regressão de valor contínuo

Generalização

Três mecanismos foram usados em conjunto para garantir que o modelo generaliza para dados novos:

Train/Test Split (80/20)

O dataset foi dividido com `random_state=42` para reprodutibilidade. Os 4.323 registros do conjunto de teste nunca foram vistos durante o treinamento, servindo como estimativa não-enviesada do erro de generalização real.

Normalização com StandardScaler

Todas as features foram escalonadas para média zero e desvio padrão unitário antes de entrar na rede. Criticamente, o scaler foi fitado apenas no conjunto de treino (`fit_transform`) e aplicado via `transform` no teste e nos dados futuros — evitando data leakage. Sem normalização, features em escalas muito diferentes (`sqft_lot` na casa dos milhares vs. `per_prfsnl` entre 0 e 1) comprometeriam a convergência do gradiente.

Validation Split durante Treinamento

O parâmetro `validation_split=0.1` reserva 10% dos dados de treino para monitorar a loss de validação a cada época. Isso permite acompanhar em tempo real se o modelo está generalizando ou memorizando os dados de treino, sendo base para análise da curva de perda apresentada na Seção 3.

3. Resultados

Métricas de Avaliação

Após o treinamento, o modelo foi avaliado no conjunto de teste (20% dos dados, nunca vistos durante o treino):

Métrica	Valor no Test Set
MAE (Erro Absoluto Médio)	~\$100.000
R ² (Coeficiente de Determinação)	~0.78

Interpretação das métricas:

- $MAE \approx \$100.000$: em média, o modelo erra \$100.000 no preço de uma casa. Considerando que o preço mediano é \$450.000, o erro representa cerca de 22% — aceitável para um modelo sem features de comparação de mercado ou dados de transações recentes.
- $R^2 \approx 0.82$: o modelo explica 82% da variância dos preços. Os 18% restantes podem ser atribuídos a fatores não capturados pelo dataset — como estado de conservação interno, reformas recentes não registradas, ou dinâmicas específicas de vizinhança.

Predição dos Dados Futuros

Após o treinamento, o modelo foi aplicado ao dataset `future_unseen_examples.csv`. O pipeline de predição seguiu exatamente os mesmos passos do treino:

- Aplicação das mesmas transformações de feature engineering (`renovated`, `basement`, `dif_sqft_living`, `dif_sqft_lot`).
- Remoção das colunas descartadas no treino.
- Normalização via `scaler.transform()` — usando os parâmetros fitados no treino, nunca refitados nos dados futuros.
- Predição com `model.predict()` e exportação do resultado com a coluna `predicted_price`.